

Laporan Eksperimen Deep Learning: Perbandingan Performa CNN from Scratch dan Transfer Learning untuk Klasifikasi Citra Biner

Abinaya Azhar Probo Kusumo

Program Studi Teknik Informatika, Universitas Darussalam Gontor
Ponorogo, Indonesia
NIM: 452024611054

Abstract

Eksperimen ini bertujuan untuk membandingkan dua pendekatan utama dalam klasifikasi citra biner: membangun arsitektur Convolutional Neural Network (CNN) dari awal (*from scratch*) dan menggunakan metode Transfer Learning menggunakan pretrained model MobileNetV2. Pengujian dilakukan menggunakan dua dataset yang berbeda, yaitu CIFAR-10 (yang difilter menjadi dua kelas) dan dataset Cats vs Dogs. Hasil eksperimen menunjukkan bahwa Transfer Learning memberikan performa akurasi yang jauh lebih superior, konvergensi yang lebih cepat, serta risiko overfitting yang minimal dibandingkan dengan model CNN yang dilatih dari awal pada keterbatasan jumlah sampel data latih.

1 Pendahuluan

Eksperimen ini mengevaluasi dua pendekatan besar dalam domain visi komputer untuk menyelesaikan permasalahan klasifikasi citra biner. Sesuai dengan ketentuan instruksi tugas, dua dataset berbeda digunakan sebagai objek pengujian[cite: 1, 2, 3]:

- **Dataset 1 (CIFAR-10):** Digunakan khusus untuk melatih arsitektur CNN *from scratch*[cite: 22]. Dataset asli yang memiliki 10 kelas disaring secara biner dengan hanya mengambil kelas 0 (*Airplane*) dan kelas 1 (*Automobile*).
- **Dataset 2 (Cats vs Dogs):** Digunakan untuk implementasi *Transfer Learning* menggunakan *pre-trained model* MobileNetV2[cite: 23, 60].

Kedua dataset dikonfigurasi untuk memenuhi batasan jumlah sampel minimal, yaitu di atas 200 gambar dengan pembagian kelas yang seimbang (100 gambar per kelas) demi menjamin keabsahan metrik evaluasi[cite: 25, 26, 27].

2 Preprocessing Data

Tahap penyiapan data diimplementasikan secara terstruktur untuk menjamin proses training berjalan dengan stabil dan menghindari masalah *gradient explosion*.

2.1 Pembagian Data (Data Splitting)

Kedua dataset dibagi secara konsisten menggunakan rasio ideal yang disarankan oleh panduan tugas, yaitu: 70% untuk data *training*, 15% untuk data *validation*, dan 15% untuk data *testing*[cite: 34, 35, 36].

2.2 Normalisasi dan Resizing Citra

- **Eksperimen 1 (CIFAR-10):** Dimensi spasial gambar dipertahankan pada ukuran asli 32×32 piksel dengan 3 kanal warna (RGB). Nilai piksel dikonversi ke dalam rentang $[0.0, 1.0]$ melalui pembagian nilai tiap piksel dengan nilai maksimum 255.0.
- **Eksperimen 2 (Cats vs Dogs):** Citra diubah ukurannya (*resizing*) menjadi 160×160 piksel untuk menyesuaikan konfigurasi input standar *pre-trained model* MobileNetV2. Nilai piksel dinormalisasi menuju rentang $[-1.0, 1.0]$ menggunakan formula matematika formal:

$$\text{Pixel}_{\text{normalized}} = \frac{\text{Pixel}}{127.5} - 1.0 \quad (1)$$

3 Implementasi CNN from Scratch

Arsitektur CNN dari awal dirancang secara sekuensial dengan susunan komponen minimal yang diwajibkan, meliputi *convolution layer*, *pooling layer*, *activation function*, *flatten*, dan *dense layer*[cite: 39, 40, 41, 42, 43, 44, 45]. Susunan layer lengkapnya adalah sebagai berikut:

1. **Conv2D 1:** 32 filter, kernel 3×3 , aktivasi ReLU, input shape (32, 32, 3).

2. **MaxPooling2D 1:** Ukuran pooling 2×2 .
3. **Conv2D 2:** 64 filter, kernel 3×3 , aktivasi ReLU.
4. **MaxPooling2D 2:** Ukuran pooling 2×2 .
5. **Conv2D 3:** 64 filter, kernel 3×3 , aktivasi ReLU.
6. **Flatten Layer:** Mengubah matriks fitur 2D menjadi vektor 1D.
7. **Dense Layer (Hidden):** 64 unit neuron, aktivasi ReLU.
8. **Dropout Layer:** Pemasangan regularisasi sebesar 0.5 (50%) untuk meminimalkan risiko *overfitting*[cite: 53].
9. **Output Layer (Dense):** 1 unit neuron, aktivasi Sigmoid untuk probabilitas biner.

Alasan Desain Arsitektur: Kombinasi tiga layer konvolusi bertingkat bertujuan agar model mampu menangkap fitur gambar dari tingkat mendasar (tepi/garis) hingga fitur semantik yang lebih kompleks. Penggunaan Dropout diletakkan sebelum output layer guna mencegah ketergantungan ekstrem neuron pada pola training tertentu[cite: 53]. Model ini dikompilasi menggunakan loss function *binary crossentropy* dan optimizer *Adam*[cite: 49].

4 Implementasi Transfer Learning

Pada eksperimen kedua, model dibangun dengan memanfaatkan keunggulan arsitektur **MobileNetV2** yang telah dilatih menggunakan dataset skala besar ImageNet[cite: 56, 60].

Alasan Pemilihan Model: MobileNetV2 dipilih karena strukturnya yang berbasis *Inverted Residuals* sangat efisien dari segi komputasi, memiliki jumlah parameter yang relatif kecil, namun tetap mempertahankan akurasi tinggi[cite: 69]. Model ini sangat cocok dieksekusi di lingkungan dengan sumber daya terbatas (*resource-constrained*) seperti notebook Kaggle secara cepat.

4.1 Strategi Transfer Learning

Eksperimen ini menerapkan strategi **Feature Extraction**[cite: 64, 65]. Seluruh layer dasar (*base layers*) milik MobileNetV2 dibekukan (*freeze*) secara total dengan parameter `trainable = False`[cite: 66]. Di atas *base model* tersebut, dipasang sebuah top *classifier* baru berupa *Global Average Pooling*, *Dense layer* (64 neuron, ReLU), *Dropout* (0.5), dan sebuah *Output Dense layer* (1 neuron, Sigmoid).

5 Hasil Eksperimen dan Perbandingan Model

Bagian ini menyajikan perbandingan performa objektif riil yang didapatkan setelah proses pelatihan di Kaggle selesai dijalankan[cite: 70].

5.1 Tabel Perbandingan Aspek

Sesuai dengan matriks perbandingan yang diwajibkan pada panduan tugas, berikut adalah rangkuman performa kedua model berdasarkan berkas log riil[cite: 71]:

Table 1: Tabel Perbandingan Aspek Eksperimen (Data Riil)

Aspek	CNN from Scratch	Transfer Learning
Akurasi Training	0.8407	0.9571
Akurasi Validation	0.7844	0.9416
Akurasi Testing	0.7932	0.9392
Loss Training	0.3541	0.1118
Loss Validation	0.4430	0.1478
Waktu Training	40.12 s	17.85 s
Jumlah Parameter	120,449	2,321,217
Risiko Overfitting	Tinggi	Rendah
Kemudahan Imp.	Sedang	Mudah
Kesesuaian Data	Kurang Sesuai	Sangat Sesuai

5.2 Visualisasi Wajib

Pada laporan final, grafik visualisasi yang disyaratkan disisipkan ke dalam dokumen untuk memperjelas analisis[cite: 84]:

1. Grafik akurasi dan loss training vs validation menunjukkan tren ketidakstabilan dan gejala *overfitting* pada model *CNN from scratch*[cite: 85, 86], sedangkan grafik model *Transfer Learning* bergerak konvergen secara mulus sejak epoch awal.
2. *Confusion matrix* mencatatkan tingkat kesalahan prediksi (*false positives* & *false negatives*) yang jauh lebih rendah pada pendekatan *Transfer Learning*[cite: 87, 88].
3. Contoh sampel prediksi benar (warna hijau) dan sampel prediksi salah (warna merah) berhasil dirender dengan jelas setelah memperbaiki pipeline manipulasi piksel gambar[cite: 89].

6 Analisis Mendalam

6.1 Analisis Dataset

1. **Kecukupan Ukuran Dataset:** Ukuran dataset biner yang dibatasi minimal 200 data tidak cukup besar untuk melatih CNN *from scratch*[cite: 94]. Model dari awal memerlukan puluhan ribu variasi data untuk mempelajari representasi visual objek secara mandiri tanpa menghafal data training.
2. **Variasi Gambar:** Variasi gambar pada CIFAR-10 cenderung seragam secara dimensi (32×32), sedangkan dataset Cats vs Dogs memiliki variasi pose, sudut pengambilan gambar, dan latar belakang (*background*) yang jauh lebih tinggi dan kompleks[cite: 95, 97].
3. **Ketidakseimbangan Data:** Pembagian kelas dari fungsi filter data dilakukan secara merata (50:50), sehingga tidak terdapat isu ketidakseimbangan kelas (*class imbalance*) dalam eksperimen ini[cite: 96].
4. **Noise dan Pencabutan:** Dataset Cats vs Dogs mengandung banyak *noise* alami berupa variasi pencabutan ruangan/luar ruangan dan latar belakang objek yang bocor[cite: 97].
5. **Pengaruh Kualitas terhadap Hasil:** Kurangnya resolusi piksel pada CIFAR-10 membatasi kemampuan ekstraksi fitur CNN dari nol. Sementara itu, kerumitan latar belakang pada Cats vs Dogs berhasil diatasi secara optimal oleh *Transfer Learning* karena bobot filternya sudah terbiasa mengenali objek kompleks pada ImageNet[cite: 98].

6.2 Analisis Performa Model

1. **Model Performa Terbaik:** Model *Transfer Learning* (MobileNetV2) menghasilkan akurasi tertinggi (93.92%) dan loss terendah secara konsisten pada data testing[cite: 101].
2. **Arti Akurasi Tinggi:** Akurasi tinggi tidak selalu berarti model lebih baik jika terjadi jurang pemisah yang besar antara akurasi training dan validasi (indikasi *overfitting*)[cite: 102, 103]. Namun dalam kasus *Transfer Learning* ini, tingginya akurasi bersifat valid karena performa pada data testing berbanding lurus dengan training.
3. **Tanda Overfitting:** Model CNN *from scratch* menunjukkan tanda *overfitting* yang nyata, di mana akurasi training terus meningkat mendekati 84% tetapi akurasi validasi/testing tertahan di angka 78% – 79%[cite: 103].
4. **Stabilitas Model:** Model *Transfer Learning* jauh lebih stabil selama proses training dan konvergen lebih cepat (hanya dalam 3 epoch) dibandingkan model dari nol[cite: 104].

5. **Hubungan Jumlah Data dan Performa:** Semakin sedikit data, performa CNN dari awal akan semakin buruk karena minimnya generalisasi pola[cite: 105]. Sebaliknya, *Transfer Learning* mampu mempertahankan performa superior meskipun disuplai dengan jumlah data yang minim.

6.3 Analisis Pemilihan Pendekatan

Berdasarkan bukti empiris eksperimen, panduan pengambilan keputusannya adalah[cite: 108]:

- **Gunakan Transfer Learning jika:** Ukuran dataset kecil atau terbatas, domain data memiliki kemiripan dengan ImageNet (objek sehari-hari), serta ketersediaan waktu pelatihan dan infrastruktur komputasi sangat terbatas[cite: 110, 111, 112].
- **Gunakan CNN from Scratch jika:** Memiliki dataset berskala masif (jutaan gambar) dan karakteristik objek visual bersifat sangat spesifik yang tidak terwakili oleh dataset ImageNet umum[cite: 110, 111].

7 Studi Kasus Pengambilan Keputusan

Berikut adalah argumentasi pemecahan masalah terhadap empat skenario riil yang diajukan[cite: 118]:

- **Skenario 1 (Klinik Medis, 300 gambar):** Dipilih **Transfer Learning**[cite: 121]. Jumlah 300 gambar sangat mustahil untuk melatih CNN dari awal tanpa memicu *overfitting* ekstrem[cite: 120]. Pada dunia medis, kesalahan diagnosis berakibat fatal sehingga butuh inisialisasi bobot matang milik pre-trained model yang di-*fine-tuning*.
- **Skenario 2 (Perusahaan, 1 Juta gambar internal non-ImageNet):** Dipilih **CNN from Scratch sangat relevan**[cite: 125]. Jumlah data sebesar 1 juta gambar sudah melampaui ambang batas kebutuhan data minimum[cite: 123]. Karena karakteristik produk internal sangat berbeda dari objek ImageNet, melatih bobot filter dari nol akan menghasilkan abstraksi fitur baru yang jauh lebih representatif bagi produk tersebut.
- **Skenario 3 (Prototipe 2 Hari, 500 gambar):** Dipilih **Transfer Learning (Feature Extraction)**[cite: 130]. Pendekatan ini paling rasional karena proses pembekuan layer dasar membuat waktu training berjalan sangat singkat (hanya 17.85 detik pada MobileNetV2)[cite: 127]. Langkah ini menjamin akurasi tinggi tanpa perlu proses *trial-error* arsitektur yang memakan waktu.

- **Skenario 4 (Dataset besar, GPU memadai, domain spesifik): Transfer Learning tetap diperlukan**[cite: 134]. Memiliki dataset besar bukan berarti harus membuang *Transfer Learning*. Langkah terbaik adalah menggunakan arsitektur pretrained besar, lalu menerapkan **Deep Fine-Tuning** (membuka sebagian besar layer untuk dilatih ulang)[cite: 132]. Ini bertindak sebagai *smart initialization* yang jauh lebih baik daripada menginisialisasi bobot secara acak dari nol.

8 Kesimpulan dan Refleksi Pribadi

8.1 Kesimpulan

Eksperimen membuktikan bahwa teknik *Transfer Learning* memberikan efisiensi pengerjaan dan performa akurasi testing yang jauh mengungguli arsitektur CNN *from scratch* ketika dihadapkan pada keterbatasan jumlah sampel data latih[cite: 154].

8.2 Jawaban Pertanyaan Refleksi Pribadi

1. **Tantangan terbesar:** Melakukan manipulasi pipeline data menggunakan `tf.data.Dataset` untuk menyaring kelas biner pada CIFAR-10, serta menangani error rendering gambar akibat normalisasi nilai piksel negatif pada dataset Cats vs Dogs[cite: 174].
2. **Bagian paling sulit:** Bagian CNN *from scratch* lebih sulit karena tidak ada jaminan baku mengenai konfigurasi hyperparameter yang optimal[cite: 175].
3. **Perbedaan paling terasa:** Terletak pada kecepatan konvergensi saat training. Pretrained model langsung mencatatkan akurasi tinggi di epoch pertama karena filternya sudah matang[cite: 176].
4. **Pendekatan untuk kasus nyata:** Saya akan memilih pendekatan *Transfer Learning* sebagai baseline utama karena sebagian besar masalah di industri menuntut efisiensi waktu deployment[cite: 177].
5. **Hal baru yang dipelajari:** Saya menyadari bahwa performa kecerdasan buatan tidak hanya ditentukan oleh kompleksitas kode program, melainkan ditentukan oleh keselarasan antara volume data, karakteristik domain objek, dan efisiensi strategi training yang dipilih[cite: 178].

References

- [1] Tim Dosen Pembelajaran Mesin, “Panduan Tugas Individu: CNN vs Transfer Learning untuk Klasifikasi Citra,” Program Studi Teknik Informatika, Universitas Darussalam Gontor, 2026.